

HỆ THỐNG TRÍ TUỆ NHÂN TẠO PHÂN TÍCH CHỈ SỐ KHỐI CƠ THỂ VÀ ĐỀ XUẤT LIỆU PHÁP CẢI THIỆN SỨC KHỎE

Vũ Tài Sang, Nguyễn Quốc Hưng
Nhóm 8, lớp CNTT 1602, Khoa Công Nghệ Thông Tin
Trường Đại Học Đại Nam, Việt Nam
ThS. Lê Trung Hiếu, ThS. Nguyễn Thái Khánh
Giảng viên hướng dẫn, Khoa Công Nghệ Thông Tin
Trường Đại Học Đại Nam, Việt Nam

Tóm tắt nội dung—Hiện nay, nhu cầu theo dõi sức khỏe cá nhân và cải thiện thể trạng ngày càng tăng cao, đặc biệt trong bối cảnh lối sống hiện đại dễ dẫn đến tình trạng thừa cân, béo phì hoặc thiếu cân. Phần lớn các ứng dụng sức khỏe hiện có mới chỉ dừng lại ở mức tính toán chỉ số BMI cơ bản, chưa có khả năng phân tích sâu dữ liệu cá nhân hay đưa ra khuyến nghị luyện tập, dinh dưỡng phù hợp. Do đó, việc phát triển một hệ thống AI có khả năng phân tích chỉ số BMI và tự động sinh kế hoạch luyện tập, dinh dưỡng cá nhân hóa là cần thiết, góp phần hỗ trợ người dùng theo dõi và cải thiện sức khỏe hiệu quả hơn.

Index Terms—Xây dựng mô hình AI phân tích các chỉ số cơ thể (BMI, tuổi, giới tính, cân nặng, chiều cao, v.v.) để đánh giá tình trạng sức khỏe. Tự động đề xuất liệu pháp cải thiện sức khỏe cá nhân hóa (ví dụ: chế độ dinh dưỡng, luyện tập, nghỉ ngơi). Thiết kế giao diện web hoặc ứng dụng cho phép người dùng nhập dữ liệu và nhận khuyến nghị ngay.

I. GIỚI THIỆU

Sức khỏe và quản lý cân nặng là mối quan tâm hàng đầu của xã hội hiện đại, nơi mà lối sống tĩnh tại và thói quen ăn uống không lành mạnh đang làm gia tăng tỷ lệ các bệnh liên quan đến cân nặng và khối cơ thể, như béo phì và thiếu cân. Việc xác định chính xác tình trạng cơ thể và xây dựng một lộ trình cải thiện cá nhân hóa là bước thiết yếu để duy trì một cơ thể khỏe mạnh và phòng ngừa bệnh tật.

Tuy nhiên, các phương pháp truyền thống thường yêu cầu sự can thiệp của chuyên gia dinh dưỡng hoặc huấn luyện viên cá nhân, gây tốn kém về thời gian và chi phí. Hơn nữa, các công cụ tự đánh giá BMI đơn thuần thường cung cấp một cái nhìn tĩnh, thiếu khả năng phân tích đa chiều các chỉ số quan trọng khác như lượng calo tiêu thụ, calo nạp vào, và thời gian ngủ. Sự thiếu sót này dẫn đến việc đề xuất các kế hoạch cải thiện mang tính chung chung, kém hiệu quả và khó duy trì.

Để giải quyết những hạn chế đó, chúng tôi đề xuất phát triển một Hệ thống Trí tuệ Nhân tạo (AI) toàn diện nhằm phân tích sâu các chỉ số sức khỏe cá nhân và tự động đề xuất liệu pháp cải thiện sức khỏe chuyên biệt. Hệ thống này được xây dựng trên nền tảng:

- Sử dụng mô hình Học máy (Machine Learning) để phân loại trạng thái cơ thể người dùng (ví dụ: Thiếu cân

nghiêm trọng, Bình thường, Béo phì) dựa trên các chỉ số đầu vào như chiều cao, cân nặng, BMI, calo nạp/tiêu hao, và thời gian ngủ.

- Tận dụng sức mạnh của Mô hình Ngôn ngữ Lớn (LLM)** Để tạo ra Kế hoạch Dinh dưỡng và Tập luyện chi tiết, cá nhân hóa theo từng ngày (N ngày) dựa trên trạng thái cơ thể được phân tích và mục tiêu sức khỏe cụ thể của người dùng.
- Triển khai dưới dạng ứng dụng web Flask** Cho phép người dùng dễ dàng nhập dữ liệu, nhận kết quả phân tích, và lưu trữ/quản lý lộ trình sức khỏe của mình thông qua cơ sở dữ liệu SQLite.

Đóng góp chính của công trình này bao gồm:

- Xây dựng một hệ thống phân tích đa yếu tố:** Thay vì chỉ dựa vào BMI, hệ thống tích hợp các chỉ số hành vi (calo, giấc ngủ) để đưa ra nhận định trạng thái cơ thể chính xác hơn.
- Ứng dụng LLM trong việc tạo kế hoạch sức khỏe cá nhân hóa:** Tự động hóa quá trình tạo ra các lộ trình chuyên nghiệp, chi tiết, với format chuẩn (Dinh dưỡng, Tập luyện, Lưu ý chung) và có khả năng lặp lại/điều chỉnh.
- Phát triển giao diện người dùng trực quan:** Tạo điều kiện cho người dùng theo dõi tiến độ, cập nhật thông tin và quản lý To-do List hàng ngày (được phân tích từ nội dung do AI tạo ra), thúc đẩy sự cam kết và kiên trì trong lộ trình cải thiện sức khỏe.

Tóm lại, hệ thống này đại diện cho một giải pháp công nghệ tiên tiến, dễ tiếp cận, giúp cá nhân hóa lộ trình cải thiện sức khỏe, mang lại hiệu quả cao hơn so với các phương pháp và công cụ đánh giá truyền thống.

A. Mục tiêu thực hiện

Mục tiêu của nghiên cứu và phát triển này là xây dựng một hệ thống ứng dụng Trí tuệ Nhân tạo hoàn chỉnh, có khả năng phân tích và cá nhân hóa lộ trình cải thiện sức khỏe. Các mục tiêu cụ thể bao gồm:

- Mục tiêu Nghiên cứu và Mô hình hóa (Research and Modeling)**

- Xây dựng và tích hợp thành công mô hình Học máy (**body_status_model_5classes.pkl**) để phân loại người dùng thành 5 nhóm trạng thái cơ thể (ví dụ: Bình thường, Béo phì), dựa trên các chỉ số đa chiều: chiều cao, cân nặng, BMI, calo nạp/tiêu hao, và thời gian ngủ.
 - Nghiên cứu và triển khai cơ chế gọi API với mô hình **Gemini 2.5 Flash** (qua hàm `try_generate_content_with_failover`) để tự động sinh ra Kế hoạch Dinh dưỡng và Tập luyện chi tiết, cá nhân hóa.
 - Thiết kế cấu trúc **Prompt Engineering** tối ưu để đảm bảo đầu ra của mô hình LLM luôn tuân thủ cấu trúc 3 phần cố định (Dinh dưỡng, Tập luyện, Lưu ý chung) và bao gồm nội dung chi tiết theo từng ngày (N ngày).
- **Mục tiêu Phát triển Ứng dụng Web (Web Application Development)**
- Phát triển ứng dụng web trên nền tảng **Flask** (`app.py`) với giao diện người dùng trực quan, hỗ trợ quy trình nhập chỉ số sức khỏe theo từng bước (`/bmi-form`).
 - Triển khai hoàn chỉnh các chức năng **Quản lý người dùng** (Đăng ký, Đăng nhập, Hồ sơ) và **Lưu trữ dữ liệu** bằng cơ sở dữ liệu **SQLite** (`database.db`), lưu trữ thông tin người dùng và kết quả phân tích AI thô (`ai_results`).
 - Xây dựng các hàm xử lý dữ liệu phức tạp (`parse_full_plan_sections`, `parse_day_details_to_todos`) để chuyển đổi kết quả văn bản thô từ AI thành các khối HTML dễ đọc và **Danh sách công việc (To-do List)** chi tiết cho từng ngày.
 - Thiết kế luồng xử lý phi đồng bộ (`routes/analyzing → /result`) để quản lý quá trình gọi API AI kéo dài, nâng cao trải nghiệm người dùng.
- **Mục tiêu Vận hành và Theo dõi Lộ trình (Operational and Tracking)**
- Phát triển chức năng **Xác nhận Lộ trình Chính thức** (`/confirm_plan`) để người dùng chọn một kết quả AI, đặt tên, và ấn định Ngày bắt đầu/kết thúc cho lộ trình.
 - Xây dựng chức năng **Theo dõi Tiến độ Hàng ngày** (`/current_plan`) cho phép người dùng xem lộ trình đang hoạt động và tương tác đánh dấu hoàn thành cho từng mục trong To-do List (dinh dưỡng và tập luyện) thông qua API `/update_todo_progress`.

B. Phương pháp Thực hiện (Implementation Methodology)

Quá trình thực hiện dự án được chia thành ba giai đoạn chính, kết hợp giữa việc mô phỏng dữ liệu, xây dựng mô hình Học máy, và tích hợp vào hệ thống web:

- 1) **Giai đoạn 1: Thu thập và Mô phỏng Dữ liệu Tự động**
 - **Mô phỏng Dữ liệu Người dùng:** Sử dụng **Google Apps Script** để tự động điền các trường thông tin

ngẫu nhiên vào một Google Form. Việc này nhằm mô phỏng dữ liệu đầu vào đa dạng từ người dùng thực tế.

- **Cấu trúc Dữ liệu:** Dữ liệu được thu thập gồm 8 trường thông tin cơ bản của người dùng:

"ho_va_ten, tuoi, gioi_tinh, chieu_cao_cm, can_nang_kg, calo_nap, calo_tieu_hao, thoi_gian_ngu"

- **Xây dựng Tập Dữ liệu:** Xuất dữ liệu từ Google Form thành tệp **CSV** với quy mô khoảng **1741 bản ghi** (tương đương với 1741 người dùng mô phỏng). Tệp CSV này được sử dụng làm cơ sở để xây dựng tập huấn luyện cho mô hình phân loại.

2) Giai đoạn 2: Tiền xử lý và Xây dựng Tập Dữ liệu

- **Tính toán Chỉ số BMI:** Trên tập dữ liệu thu thập được, tiến hành tính toán chỉ số BMI (*Body Mass Index*) cho mỗi bản ghi theo công thức:

$$BMI = \frac{\text{Cân nặng (kg)}}{(\text{Chiều cao (m)})^2}$$

- **Gán Nhãn Phân loại:** Dựa trên chỉ số BMI và các tiêu chí sức khỏe liên quan (có thể được bổ sung từ các trường Calo và Giấc ngủ), tiến hành gán nhãn mục tiêu (*Target Label*) cho mỗi bản ghi. Các nhãn này tương ứng với 5 lớp trạng thái cơ thể của mô hình (`LABEL_MAP` trong `app.py`):

- a) Thiếu cân nghiêm trọng
- b) Thiếu cân
- c) Bình thường
- d) Thừa cân
- e) Béo phì

- **Tập Dữ liệu Cuối cùng:** Tập dữ liệu cuối cùng được sử dụng để huấn luyện mô hình bao gồm các biến độc lập (*features*) [`'chieu_cao_cm', 'can_nang_kg', 'calo_nap', 'calo_tieu_hao', 'thoi_gian_ngu', 'bmi'`] và biến phụ thuộc (*target*) là Nhãn phân loại.

3) Giai đoạn 3: Huấn luyện và Tích hợp Mô hình Phân loại

- **Thuật toán Huấn luyện:** Lựa chọn thuật toán **Random Forest (Rừng ngẫu nhiên)** để huấn luyện mô hình phân loại trạng thái cơ thể do thuật toán này có khả năng xử lý tốt các tập dữ liệu có kích thước vừa phải và đưa ra kết quả phân loại ổn định.
- **Đánh giá Mô hình:** Sử dụng các chỉ số đánh giá tiêu chuẩn (ví dụ: Độ chính xác - *Accuracy*, *F1-Score*) để xác định hiệu suất của mô hình.
- **Lưu trữ Mô hình:** Mô hình sau khi huấn luyện thành công được lưu trữ dưới dạng tệp **pickle** (`body_status_model_5classes.pkl`) để tái sử dụng.
- **Tích hợp vào Hệ thống:** Tải mô hình đã lưu (`pickle.load`) vào ứng dụng Flask (`app.py`) để

phục vụ chức năng dự đoán trạng thái cơ thể người dùng trong luồng phân tích (/result).

II. CÁC CÔNG TRÌNH LIÊN QUAN

Trong những năm gần đây, sự kết hợp giữa **trí tuệ nhân tạo (AI)** và **khoa học sức khỏe** đã tạo ra một xu hướng nghiên cứu mạnh mẽ hướng đến việc tự động hoá phân tích thể trạng con người và hỗ trợ ra quyết định y tế, dinh dưỡng. Nhiều công trình trong và ngoài nước đã tập trung vào việc khai thác các mô hình học sâu (*Deep Learning*) để ước lượng các chỉ số sinh học, trong đó có **chỉ số khối cơ thể (BMI)** và các chỉ số liên quan đến tỷ lệ mỡ, cơ, và mức độ béo phì.

A. Nghiên cứu liên quan

1. Các nghiên cứu quốc tế

Trên thế giới, các mô hình học sâu như **Convolutional Neural Network (CNN)** và **Vision Transformer (ViT)** đã được ứng dụng để phân loại hình thể, ước lượng chỉ số BMI từ hình ảnh cơ thể. Một số công trình tiêu biểu có thể kể đến:

- **Kocabey et al. (2017)**: Nghiên cứu mô hình CNN để dự đoán BMI từ hình ảnh khuôn mặt, đạt độ chính xác tương đối cao khi so sánh với BMI thực tế, mở ra hướng ứng dụng thị giác máy trong đánh giá thể trạng.
- **Mordan et al. (2019)**: Đề xuất phương pháp ước lượng BMI dựa trên ảnh toàn thân sử dụng mạng *ResNet-50* kết hợp với biểu đồ khung xương 3D trích xuất từ ảnh người.
- **Han et al. (2020)**: Giới thiệu hệ thống phân tích hình ảnh y tế kết hợp dữ liệu nhân trắc học và học sâu để đánh giá rủi ro sức khỏe liên quan đến béo phì, chứng minh hiệu quả của việc tích hợp dữ liệu đa nguồn.
- **WHO AI Health Challenge (2022)**: Các nhóm tham gia sử dụng AI để xác định mức độ béo phì qua ảnh và dữ liệu sức khỏe, hướng đến xây dựng mô hình chẩn đoán và khuyến nghị toàn cầu.

Các nghiên cứu trên cho thấy khả năng mạnh mẽ của AI trong việc *đánh giá thể trạng* và *dự đoán chỉ số sức khỏe*, tuy nhiên phần lớn vẫn tập trung vào việc nhận dạng hoặc ước lượng chỉ số, mà chưa chuyển hóa sang bước **đề xuất liệu pháp cải thiện sức khỏe cá nhân hóa**.

2. Các nghiên cứu trong nước

Tại Việt Nam, hướng nghiên cứu ứng dụng AI trong lĩnh vực sức khỏe – thể hình mới được chú trọng trong vài năm gần đây. Một số công trình đáng chú ý gồm:

- **Nguyễn et al. (2021)**: Xây dựng hệ thống nhận diện dáng người và tính toán BMI từ ảnh 2D, sử dụng mô hình MobileNet nhằm giảm tải tính toán cho các thiết bị di động.
- **Lê et al. (2022)**: Đề xuất mô hình học máy kết hợp dữ liệu hình ảnh và thông tin cơ bản (tuổi, chiều cao, cân nặng) để đánh giá nguy cơ thừa cân.
- **Đề án “AI cho sức khỏe cộng đồng” (2023)**: Hướng đến việc ứng dụng học sâu và xử lý ảnh để phát hiện sớm béo phì và các bệnh liên quan thông qua dữ liệu người dùng thu thập qua thiết bị di động.

Mặc dù đã có những bước tiến đáng kể, hầu hết các hệ thống hiện nay vẫn dừng ở mức **phân loại** hoặc **ước lượng BMI**, chưa có khả năng **phân tích đa chiều về thể trạng**, cũng như **đề xuất liệu pháp cải thiện phù hợp** dựa trên dữ liệu cá nhân.

3. Khoảng trống nghiên cứu (Research Gap)

Qua tổng quan các công trình trên, có thể nhận thấy rằng:

- Các hệ thống hiện tại chủ yếu tập trung vào **dự đoán chỉ số BMI** hoặc **phân loại hình thể**, chưa tích hợp gợi ý hành vi hoặc khuyến nghị cải thiện.
- Thiếu sự kết hợp giữa **AI phân tích hình ảnh cơ thể** và **AI ngôn ngữ** để sinh ra nội dung khuyến nghị mang tính cá nhân hoá.
- Hầu hết mô hình chưa chú trọng đến tính **thích ứng thời gian thực**, cũng như khả năng cập nhật dữ liệu người dùng theo thời gian.

4. Đóng góp của đề tài

Đề tài “**Hệ thống trí tuệ nhân tạo phân tích chỉ số khối cơ thể và đề xuất liệu pháp cải thiện sức khỏe**” hướng tới việc khắc phục những hạn chế trên bằng cách:

- Ứng dụng mô hình CNN hoặc YOLOv8 để trích xuất đặc trưng hình thể người dùng từ ảnh hoặc video.
- Tính toán và phân loại mức độ BMI, tỷ lệ mỡ – cơ – xương theo dữ liệu thực tế.
- Kết hợp mô hình ngôn ngữ lớn (LLM) để đề xuất liệu pháp dinh dưỡng, tập luyện và nghỉ ngơi cá nhân hoá.
- Phát triển giao diện thân thiện cho phép người dùng theo dõi tiến trình và nhận phản hồi AI theo thời gian thực.

Nhờ đó, hệ thống không chỉ dừng lại ở việc đánh giá thể trạng, mà còn đóng vai trò như một *huấn luyện viên ảo (AI Trainer)* có khả năng học hỏi và tương tác thông minh, góp phần nâng cao sức khỏe cộng đồng và hỗ trợ tự chăm sóc bản thân trong kỷ nguyên số.

B. Các phương pháp tiếp cận dựa trên Học sâu (Deep Learning Approaches)

Trong xu hướng hiện nay, các phương pháp Học sâu (*Deep Learning Approaches*) đã và đang trở thành nền tảng cốt lõi cho các hệ thống trí tuệ nhân tạo trong lĩnh vực phân tích hình dạng và thành phần cơ thể người (*Body Composition – BC*). Nhờ khả năng trích xuất các đặc trưng hình học và sinh trắc học phức tạp từ dữ liệu hình ảnh, các mô hình Học sâu vượt trội rõ rệt so với các phương pháp đo lường truyền thống.

1) *Kiến trúc Học sâu cho Ước tính Hình dạng Cơ thể và Chỉ số Sinh trắc học*: Các mô hình Học sâu đã cung cấp các giải pháp phi tiếp xúc và tự động trong việc ước tính trọng lượng, tỷ lệ mỡ, và chỉ số khối cơ thể (BMI). Các hướng tiếp cận chính bao gồm:

a) *Mạng Nơ-ron Tích chập (CNNs)*: Mạng CNN là kiến trúc nền tảng trong phân tích hình ảnh 2D/3D để tái tạo hình dạng cơ thể. Một số hướng phát triển tiêu biểu:

- **Hồi quy nhiều tầng**: Sử dụng CNN huấn luyện trên các cặp dữ liệu cảm biến và bản đồ 3D để dự đoán hình dạng cơ thể 3D, sau đó dùng làm đầu vào cho một mạng khác

nhằm ước lượng các chỉ số sinh trắc học (chu vi, tỷ lệ mỡ, v.v.).

- **Trích xuất đặc trưng sâu:** Kết hợp đặc trưng hình học 2D và 3D với *deep feature extraction* giúp cải thiện hiệu suất ước lượng BMI và phân loại thể trạng.
- **Phân tích y tế:** Thuật toán như *DeepLabv3+* đã được ứng dụng để tự động trích xuất thành phần mỡ nội tạng và mỡ dưới da từ ảnh CT, mang lại độ chính xác cao trong chẩn đoán béo phì.

b) *Vision Transformers (ViT) và Mô hình Nền tảng:* Kiến trúc Transformer, ban đầu dành cho xử lý ngôn ngữ tự nhiên, hiện được mở rộng mạnh mẽ trong thị giác máy tính:

- **Ước tính lưới cơ thể (HME):** Các mô hình nền tảng như SMPLer-X tận dụng Vision Transformer để tái tạo lưới 3D toàn thân từ ảnh 2D.
- **Transformer nhận biết thành phần:** Mô hình OSX sử dụng mã hóa toàn cục và giải mã cục bộ, tăng độ chính xác khi tái tạo chi tiết cơ thể (mặt, tay, chi).
- **Độ chính xác cao:** Các nghiên cứu gần đây khẳng định ViT có tiềm năng lớn trong đo lường nhân trắc học tự động.

c) *Mạng Đối nghịch Tạo sinh (GAN) cho Chuẩn hóa Tư thế:* Một thách thức lớn khi sử dụng ảnh 2D từ thiết bị di động là sự khác biệt tư thế và góc chụp. GAN được sử dụng để giảm thiểu này:

- **PN-GAN (Pose Normalization GAN):** Tạo ảnh người trong tư thế chuẩn hóa giúp mô hình học đặc trưng hình học ổn định, không bị ảnh hưởng bởi góc chụp.
- **Ứng dụng:** Kỹ thuật này cải thiện đáng kể độ chính xác của mô hình hồi quy BMI từ ảnh thật.

2) *Mô hình Học sâu Đa phương thức và Lai (Multimodal and Hybrid Models):* Để đạt độ chính xác y sinh cao, nhiều nghiên cứu đã tích hợp các dạng dữ liệu khác nhau:

- **AI đa phương thức:** Kết hợp ảnh X-quang, dữ liệu lâm sàng (EHRs) và nhân trắc học trong mô hình “late fusion” đã đạt hệ số tương quan Pearson tới 0.85 với thể tích mỡ dưới da và 0.76 với mỡ nội tạng.
- **Hồi quy lai:** Kết hợp đặc trưng sâu từ CNN với các bộ học máy như SVR, XGBoost, hoặc MLP để dự đoán Tỷ lệ Mỡ Cơ thể (BFP). Một ví dụ nổi bật là mô hình SVR-EANN (Support Vector Regression – Emotional ANN) cho kết quả vượt trội so với các mô hình thuần túy.

3) *Ứng dụng Học sâu trong Hệ thống Khuyến nghị (Recommendation Systems):* Bên cạnh phân tích hình ảnh, các mô hình Học sâu còn được triển khai để tạo ra các khuyến nghị cá nhân hoá:

- **Xử lý ngôn ngữ và LSTM:** Trong các hệ thống huấn luyện sức khỏe ảo, mạng LSTM phân cấp và mô-đun NLU được sử dụng để hiểu ngữ cảnh, ý định người dùng, từ đó sinh ra khuyến nghị dinh dưỡng phù hợp.
- **Nhận dạng thực phẩm:** Các hệ thống như *Food Weight Estimation CNN* có khả năng nhận dạng món ăn và ước lượng trọng lượng thực phẩm qua ảnh smartphone với độ chính xác lên tới 89.6%, hỗ trợ theo dõi khẩu phần hiệu quả.

a) *Tổng kết:* Nhìn chung, các phương pháp Học sâu đang cung cấp một khung kỹ thuật toàn diện — từ tái tạo hình thể 3D, ước lượng BMI, phân tích mỡ nội tạng, cho đến tạo ra các liệu pháp cá nhân hóa dựa trên hành vi và dinh dưỡng. Đây chính là nền tảng kỹ thuật cho việc phát triển hệ thống **AI huấn luyện viên sức khỏe ảo (AI Health Trainer)** trong đề tài này.

III. QUÁ TRÌNH THU NHẬP DỮ LIỆU (DATA COLLECTION PROCESS)

Quá trình xây dựng tập dữ liệu cho dự án được thực hiện bằng phương pháp mô phỏng tự động nhằm đảm bảo tính đa dạng và số lượng bản ghi cần thiết cho việc huấn luyện mô hình Học máy.

A. Công cụ và Phương pháp Mô phỏng

- **Google Forms:** Được sử dụng làm giao diện nhập liệu mô phỏng, với các trường thông tin tương ứng với các đặc trưng của người dùng.
- **Google Apps Script (GAS):** Đây là công cụ chính được sử dụng để tự động hóa quá trình điền và gửi phản hồi (responses) lên Google Form. Chức năng `submitUnderweightResponses()` trong GAS đã được sử dụng để tạo ra các bản ghi.
- **Nguyên tắc Ngẫu nhiên hóa Dữ liệu:** Dữ liệu được tạo ra ngẫu nhiên nhưng có kiểm soát, sử dụng các mảng dữ liệu mẫu (names, ages, heights, weights, v.v.) và hàm `Math.floor(Math.random() * array.length)` trong GAS để chọn ngẫu nhiên giá trị cho từng trường.

B. Cấu trúc Tập Dữ liệu Mô phỏng

Mỗi bản ghi đại diện cho một hồ sơ người dùng, được mô phỏng với 8 trường dữ liệu đầu vào cốt lõi như sau:

STT	Trường Dữ liệu (Biến)	Khoảng Giá trị (Mô phỏng)
1	ho_va_ten (Tên)	Từ danh sách mẫu (100 tên)
2	tuoi (Tuổi)	18 đến 47 (30 giá trị)
3	gioi_tinh (Giới tính)	01 (Nam) hoặc 02 (Nữ)
4	chieu_cao_cm (Chiều cao)	140 cm đến 209 cm
5	can_nang_kg (Cân nặng)	30 kg đến 89 kg
6	calo_nap (Calo nạp)	1500 kcal đến 2450 kcal (bù đắp)
7	calo_tieu_hao (Calo tiêu hao)	1500 kcal đến 2450 kcal (hoạt động)
8	thoi_gian_ngu (Giờ ngủ)	4, 5, 6, 7, 8 giờ

C. Tiền xử lý và Xây dựng Nhân

Tập dữ liệu thô sau khi xuất từ Google Form dưới dạng tệp CSV (`data_labeled.csv` với tổng số bản ghi khoảng **1741**) được tiến hành tiền xử lý trong mã Python (`model.py`) như sau:

- 1) **Tính toán Chỉ số Khối Cơ thể (BMI):** Sử dụng chiều cao và cân nặng để tính BMI cho mỗi bản ghi:

$$BMI = \frac{\text{Cân nặng (kg)}}{(\text{Chiều cao (m)})^2}$$

2) **Gán Nhãn Mục tiêu:** Chỉ số BMI được sử dụng để gán nhãn trạng thái cơ thể (label) theo phân loại chuẩn (như trong hàm `classify_bmi`), tạo ra 5 lớp:

- 0: Thiếu cân nghiêm trọng ($BMI < 16$)
- 1: Thiếu cân ($16 \leq BMI < 18.5$)
- 2: Bình thường ($18.5 \leq BMI < 25$)
- 3: Thừa cân ($25 \leq BMI < 30$)
- 4: Béo phì ($BMI \geq 30$)

3) **Tập Đặc trưng (Features):** Tập dữ liệu cuối cùng được chuẩn bị với các đặc trưng độc lập (features) ['chieu_cao_cm', 'can_nang_kg', 'calo_nap', 'calo_tieu_hao', 'thoi_gian_ngu', 'bmi'] và biến mục tiêu (target) là label để tiến hành huấn luyện mô hình.

IV. PHÂN TÍCH KHỐI CHỈ SỐ CƠ THỂ VÀ ĐƯA LIỆU PHÁP BẰNG AI

Quá trình Phân tích Khối chỉ số Cơ thể và Đề xuất Liệu pháp Cải thiện Sức khỏe là cốt lõi của hệ thống, kết hợp giữa mô hình học máy truyền thống và trí tuệ nhân tạo tạo sinh (Generative AI) để mang lại giải pháp cá nhân hóa.

A. Giải quyết vấn đề và lộ trình hệ thống

Vấn đề chính mà dự án đặt ra là vượt qua hạn chế của các công cụ đánh giá sức khỏe tĩnh, vốn chỉ dựa vào chỉ số BMI đơn thuần. Hệ thống này giải quyết vấn đề bằng cách áp dụng một lộ trình hai giai đoạn thông minh:

1) Cấu trúc giải pháp hai giai đoạn:

- **Giai đoạn Phân tích (Analysis - Học máy):** Sử dụng mô hình **Random Forest** để phân loại trạng thái cơ thể người dùng (body status) một cách chính xác. Mô hình không chỉ dựa vào BMI mà còn kết hợp với 5 chỉ số hành vi quan trọng khác (Calo nạp, Calo tiêu hao, Giờ ngủ), tạo ra một bức tranh sức khỏe toàn diện hơn.
- **Giai đoạn Đề xuất (Prescription - AI Tạo sinh):** Dựa trên kết quả phân loại từ Giai đoạn 1 (ví dụ: "Béo phì" hoặc "Thiếu cân"), hệ thống kích hoạt API **Gemini 2.5 Flash** để xây dựng kế hoạch dinh dưỡng và tập luyện chi tiết, cá nhân hóa.

2) **Lộ trình Dữ liệu và Tương tác Người dùng:** Toàn bộ quy trình được quản lý trên nền tảng **Flask** (app.py) và cơ sở dữ liệu **SQLite**:

- **Nhập liệu (form_bmi.html):** Người dùng cung cấp 6 chỉ số đầu vào.
- **Xử lý Dữ liệu:** Hệ thống tính toán BMI và gọi mô hình **Random Forest** để dự đoán trạng thái cơ thể.
- **Tạo Liệu pháp:** Dữ liệu phân tích và các thông số cá nhân được đưa vào Prompt Engineering để LLM sinh ra văn bản kế hoạch có cấu trúc **JSON** cố định.
- **Hiển thị và Lưu trữ (result.html):** Kết quả JSON được phân tích thành các phần (Tổng quan, Chi tiết ngày) và được lưu vào bảng `ai_results`.
- **Theo dõi (current_plan.html):** Kế hoạch được kích hoạt thành Lộ trình Chính thức, sử dụng hàm `parse_day_details_to_todos` để tạo ra các **To-do**

List tương tác, giúp người dùng theo dõi và cập nhật tiến độ hàng ngày trong bảng `user_plan_progress`.

B. Phân loại Khối cơ thể bằng thuật toán Random Forest

Thuật toán **Random Forest (Rừng ngẫu nhiên)** được chọn làm mô hình phân loại chính do tính ổn định, khả năng xử lý tốt các tập dữ liệu có kích thước vừa phải và đưa ra tầm quan trọng của các đặc trưng.

1) Mô hình và Tải Đặc trưng:

- **Tải Mô hình:** Mô hình đã được huấn luyện (`model.py`) được lưu trữ dưới dạng `.pkl` và tải vào ứng dụng **Flask** (app.py) bằng thư viện `pickle` khi hệ thống khởi động.
- **Đặc trưng Đầu vào:** Mô hình sử dụng tập 6 đặc trưng sau để dự đoán (như trong mã app.py):
['chieu_cao_cm', 'can_nang_kg', 'calo_nap', 'calo_tieu_hao', 'thoi_gian_ngu', 'bmi']

2) Quá trình Phân loại:

- 1) **Tính toán BMI:** Chỉ số BMI được tính toán lại trong app.py từ chiều cao và cân nặng người dùng (đơn vị cm và kg).
- 2) **Dự đoán Lớp:** Tập dữ liệu đầu vào được chuyển thành **DataFrame Pandas** và đưa vào mô hình đã tải (`model.predict()`) để dự đoán nhãn số (0-4).
- 3) **Ánh xạ Nhãn:** Kết quả số được ánh xạ sang văn bản Tiếng Việt thông qua `LABEL_MAP` (ví dụ: 4 → "Béo phì"). Nhãn văn bản này sau đó được sử dụng làm thông tin quan trọng nhất trong prompt gửi đến **Gemini 2.5 Flash** để định hướng việc tạo ra liệu pháp cải thiện sức khỏe.

C. Đề xuất Liệu pháp Bằng AI Tạo sinh (Gemini 2.5 Flash)

1) **Chức năng Tạo Sinh và Prompt Engineering:** Module này sử dụng API của Gemini để tạo ra nội dung. Prompt được thiết kế chuyên biệt, tích hợp **kết quả phân loại** từ **Random Forest** cùng với các thông số cá nhân khác (tuổi, giới tính, calo nạp/tiêu hao) để yêu cầu Gemini tạo ra một kế hoạch dinh dưỡng và tập luyện N ngày.

2) **Cấu trúc Đầu ra và Tương tác:** Để đảm bảo khả năng tích hợp, prompt yêu cầu Gemini trả về kết quả dưới dạng **JSON** có cấu trúc. Đầu ra này sau đó được xử lý bằng hàm `parse_full_plan_sections` trong app.py để trích xuất các phần sau và hiển thị trên giao diện:

- **Tổng quan:** Kế hoạch Dinh dưỡng và Tập luyện Tổng quan, Ghi chú chung.
- **Chi tiết Ngày:** Danh sách các mục tiêu dinh dưỡng và tập luyện được mã hóa Markdown cho từng ngày.

Cơ chế `try_generate_content_with_failover` cũng được sử dụng để quản lý danh sách `API_KEYS` dự phòng, đảm bảo rằng quá trình gọi API diễn ra liên tục và ổn định.

V. KẾT QUẢ

A. KẾT QUẢ HUẤN LUYỆN VÀ ĐÁNH GIÁ MÔ HÌNH

Mô hình phân loại trạng thái cơ thể được xây dựng dựa trên thuật toán **Random Forest Classifier** trên tập dữ liệu mô phỏng

khoảng 1741 bản ghi, đã được xử lý cân bằng dữ liệu bằng kỹ thuật **SMOTE** (*Synthetic Minority Oversampling Technique*) trong tệp `model.py`.

1) *Cấu hình Mô hình và Kết quả Tổng thể*: Mô hình được huấn luyện sử dụng 6 đặc trưng đầu vào (`chieu_cao_cm`, `can_nang_kg`, `calo_nap`, `calo_tieu_hao`, `thoi_gian_ngu`, và `bmi`) với các siêu tham số tối ưu hóa:

- **Số cây (`n_estimators`):** 300
- **Chiều sâu tối đa (`max_depth`):** 12
- **Số mẫu tối thiểu để phân tách (`min_samples_split`):** 4
- **Độ chính xác Tổng thể (*Overall Accuracy*):** Mô hình đạt độ chính xác **98%** trên tập kiểm tra (20% dữ liệu), chứng tỏ khả năng phân loại trạng thái cơ thể rất cao.

Hình 1. Ma trận nhầm lẫn của mô hình Random Forest trên tập dữ liệu kiểm tra.

2) *Phân tích Ma trận Nhầm lẫn và Báo cáo Phân loại*:

a) *Báo cáo Phân loại (*Classification Report*)*: Bảng 1 cho thấy hiệu suất của mô hình trên từng lớp trạng thái. Tất cả các lớp đều đạt chỉ số F1-Score cao, đặc biệt là nhóm **Bình thường** (Lớp 2) đạt 1.00.

Bảng 1

BÁO CÁO PHÂN LOẠI (CLASSIFICATION REPORT) THEO TỪNG LỚP

Nhân Thể trạng	Precision	Recall	F1-Score	Hỗ trợ
0 (Thiếu cân N.Trọng)	0.96	0.95	0.96	60
1 (Thiếu cân)	0.97	0.97	0.97	64
2 (Bình thường)	1.00	1.00	1.00	76
3 (Thừa cân)	0.97	0.97	0.97	64
4 (Béo phì)	0.99	0.99	0.99	83
Weighted Avg	0.98	0.98	0.98	347

b) *Ma trận Nhầm lẫn (*Confusion Matrix*)*: Ma trận nhầm lẫn (xem trong Hình 1) xác nhận độ chính xác cao của mô hình. Các lỗi phân loại chủ yếu xảy ra giữa các ranh giới lớp, điều này là phổ biến và chấp nhận được:

- 3 trường hợp **Thiếu cân nghiêm trọng** (Lớp 0) bị phân loại nhầm thành **Thiếu cân** (Lớp 1).
- 2 trường hợp **Thừa cân** (Lớp 3) bị phân loại nhầm thành **Bình thường** (Lớp 2).


Các lỗi này chỉ chiếm tỷ lệ rất nhỏ trên tổng số, chứng minh mô hình đủ tin cậy để tích hợp vào hệ thống phân tích trong tệp `app.py`. Mô hình sau đó được lưu trữ dưới dạng `body_status_model_5classes.pkl`.

B. KẾT QUẢ HOẠT ĐỘNG


Hệ thống **Hệ thống Trí tuệ Nhân tạo Phân tích Chỉ số Khối Cơ thể và Đề xuất Liệu pháp Cải thiện Sức khỏe** đã được triển khai thành công dưới dạng ứng dụng web hoàn chỉnh, sử dụng framework **Flask** và cơ sở dữ liệu **SQLite**. Kết quả hoạt động chứng minh khả năng tích hợp hiệu quả giữa mô hình Học máy, API AI tạo sinh và giao diện người dùng tương tác.

1) *Cơ chế Quản lý Hệ thống và Người dùng*:

- **Xác thực và Bảo mật**: Chức năng đăng ký (`/register`) và đăng nhập (`/login`) được xây dựng an toàn, sử dụng hàm băm mật khẩu (`generate_password_hash` từ `werkzeug.security`) để bảo vệ dữ liệu người dùng được lưu trữ trong bảng `users`.




Hình 2. Màn hình đăng ký

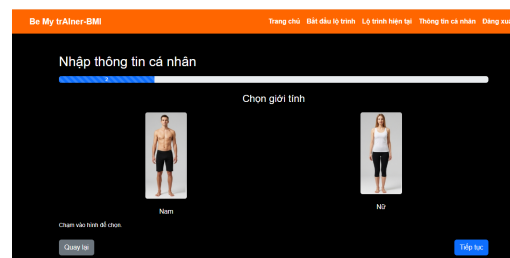


Hình 3. Màn hình đăng nhập


- **Thu thập Dữ liệu Đa bước**: Giao diện nhập liệu (`form_bmi.html`) được thiết kế với tính năng chuyển đổi bước (*multi-step form*) sử dụng JavaScript, cho phép người dùng cung cấp 8 trường thông tin (từ họ tên đến các chỉ số sức khỏe) một cách có tổ chức, cải thiện trải nghiệm và đảm bảo tính đầy đủ của dữ liệu.



Hình 4. Các bước điền thông tin cần thiết



Hình 5. Các bước điền thông tin cần thiết




Hình 6. Các bước điền thông tin cần thiết



Hình 7. Các bước điền thông tin cần thiết

2) Hiệu suất và Tính ổn định của Module AI:

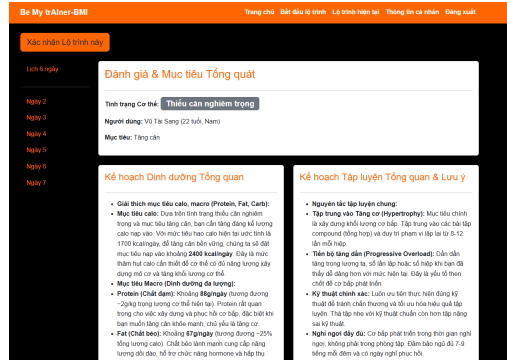
- **Phân tích Tốc thời bằng Học máy:** Ngay sau khi nhập liệu, hệ thống tải mô hình `body_status_model_5classes.pkl` và sử dụng 6 đặc trưng đầu vào để dự đoán trạng thái cơ thể người dùng. Kết quả phân loại này là thông số chính được truyền vào mô hình AI tạo sinh.
- **Đảm bảo Độ tin cậy của API Gemini:** Cơ chế dự phòng (*Failover*) đã được triển khai thông qua hàm `try_generate_content_with_failover`, sử dụng danh sách `API_KEYS`. Nếu việc gọi **API Gemini 2.5 Flash** thất bại do lỗi giới hạn hoặc lỗi mạng, hệ thống tự động chuyển sang khóa API tiếp theo, duy trì sự ổn định của quá trình đề xuất liệu pháp.
- **Tích hợp Dữ liệu có Cấu trúc:** Hệ thống yêu cầu LLM trả về đầu ra ở định dạng **JSON** có cấu trúc, bao gồm các trường chi tiết như `full_nutrition_plan` và `daily_plans`. Kết quả thô này được lưu vào bảng `ai_results` và được xử lý bằng hàm `parse_full_plan_sections` để phân tách, giúp hiển thị nội dung chi tiết và dễ đọc trên giao diện `result.html`.



Hình 8. Quá trình phân tích dữ liệu

3) Quản lý và Theo dõi Lộ trình Cá nhân hóa:

- **Kích hoạt và Lưu trữ Lộ trình:** Người dùng có thể xác nhận bất kỳ kết quả AI nào thành một lộ trình chính thức,



Hình 9. Kết quả phân tích

được lưu trữ trong bảng `user_plans` với tên, ngày bắt đầu và ngày kết thúc cụ thể, tạo thành một kế hoạch hành động theo thời gian thực.

- **Chuyển đổi sang To-do List:** Hệ thống sử dụng hàm `parse_day_details_to_todos` để phân tích nội dung kế hoạch hàng ngày (được trả về ở định dạng Markdown) thành danh sách các nhiệm vụ (**To-do List**) chi tiết cho dinh dưỡng và tập luyện.
- **Theo dõi Tiến độ Tương tác:**
 - 1) Giao diện `current_plan.html` cho phép người dùng đánh dấu hoàn thành từng mục To-do.
 - 2) Tiến trình này được cập nhật theo thời gian thực (sử dụng **AJAX** qua route `/update_todo_progress`) và được lưu trữ dưới dạng danh sách JSON (`completed_todos`) trong bảng `user_plan_progress`, cung cấp một công cụ trực quan để theo dõi cam kết và hiệu suất cá nhân.

VI. KẾT LUẬN

Nghiên cứu này đã thành công trong việc thiết kế và triển khai **Hệ thống Trí tuệ Nhân tạo Phân tích Chỉ số Khối Cơ thể và Đề xuất Liệu pháp Cải thiện Sức khỏe**, tích hợp hiệu quả giữa Học máy truyền thống và Công nghệ AI Tạo sinh. Hệ thống đã giải quyết được vấn đề thiếu tính cá nhân hóa và khả năng theo dõi của các công cụ đánh giá sức khỏe đơn thuần.

A. Tóm tắt Đóng góp Chính

- 1) **Phân tích Đa chiều:** Phát triển và tích hợp thành công mô hình **Random Forest** để phân loại trạng thái cơ thể dựa trên 6 đặc trưng đầu vào (*features*), thay vì chỉ dựa vào chỉ số BMI.
- 2) **Cá nhân hóa bằng LLM:** Ứng dụng đột phá **Google Gemini 2.5 Flash** để tự động sinh ra kế hoạch dinh dưỡng và tập luyện chi tiết, có cấu trúc JSON, hoàn toàn phù hợp với trạng thái cơ thể được phân loại.
- 3) **Hệ thống Quản lý Hành động:** Xây dựng ứng dụng web **Flask** toàn diện với chức năng quản lý người dùng, cơ chế *failover* cho API, và đặc biệt là khả năng chuyển đổi kế hoạch AI thành **To-do List** tương tác, giúp người dùng theo dõi và duy trì lộ trình.

B. Kết quả Đạt được

Các mục tiêu đề ra đã được hoàn thành với kết quả cụ thể như sau:

- **Hiệu suất Phân loại Cao:** Mô hình Random Forest đạt độ chính xác 98% trên tập kiểm tra, chứng minh tính tin cậy cao trong việc phân loại 5 trạng thái cơ thể.
- **Tính ổn định của Hệ thống:** Triển khai thành công cơ chế quản lý API Key dự phòng (*failover*), đảm bảo quá trình gọi AI để sinh nội dung diễn ra liên tục.
- **Khả năng Theo dõi Tương tác:** Hệ thống đã chứng minh được khả năng chuyển đổi nội dung văn bản phức tạp từ LLM thành các mục tiêu **To-do List** có thể tương tác và lưu trữ tiến độ hàng ngày trong cơ sở dữ liệu SQLite, thúc đẩy sự cam kết của người dùng.

C. Hướng Phát triển Trong Tương lai

Để nâng cao hơn nữa giá trị và tính ứng dụng của đề tài, các hướng phát triển tiếp theo có thể bao gồm:

- 1) **Mở rộng Tập dữ liệu và Đặc trưng:** Tăng cường tập dữ liệu huấn luyện bằng dữ liệu thực tế và tích hợp các chỉ số sức khỏe sâu hơn (ví dụ: tỉ lệ mỡ cơ thể, khối lượng cơ), từ đó cải thiện độ chính xác và tính chuyên sâu của mô hình phân loại.
- 2) **Phản hồi Vòng lặp (Feedback Loop):** Phát triển chức năng cho phép người dùng nhập phản hồi về hiệu quả của lộ trình. Sử dụng dữ liệu phản hồi này để huấn luyện lại hoặc tinh chỉnh prompt LLM, cho phép AI tự động điều chỉnh kế hoạch trong tương lai.
- 3) **Cải tiến Giao diện:** Chuyển đổi giao diện người dùng sang các công nghệ Front-end hiện đại hơn (ví dụ: React, Vue.js) để cải thiện trải nghiệm và tối ưu hóa cho thiết bị di động.

VII. LỜI CẢM ƠN

Chúng tôi xin bày tỏ lòng biết ơn sâu sắc đến ThS. Lê Trung Hiếu và ThS. Nguyễn Thái Khánh vì đã tận tình hướng dẫn, hỗ trợ và định hướng trong suốt quá trình thực hiện đề tài. Sự chỉ dẫn quý báu của thầy đã giúp chúng tôi hiểu sâu hơn về các khía cạnh kỹ thuật, tối ưu mô hình cũng như cách triển khai thực hiện đề tài.

Ngoài ra, chúng tôi cũng xin gửi lời cảm ơn đến các giảng viên trong khoa đã cung cấp nền tảng kiến thức vững chắc, giúp chúng tôi có đủ hành trang để hoàn thành nghiên cứu này. Đồng thời, chúng tôi trân trọng sự hỗ trợ từ bạn bè và gia đình đã luôn động viên và khích lệ trong suốt quá trình nghiên cứu.

Cuối cùng, xin chân thành cảm ơn tất cả những người đã góp phần giúp chúng tôi hoàn thiện đề tài này!

TÀI LIỆU

- [1] E. Kocabey, M. Ofli, and I. Weber, "Using computer vision techniques to predict BMI from face images," in *Proceedings of the 23rd ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 2017.
- [2] T. Mordan, L. Simon, and P. Luc, "Estimating body shape and BMI from single-view images using deep convolutional neural networks," *Computer Vision and Image Understanding*, vol. 186, pp. 102–110, 2019.
- [3] J. Han, Y. Kim, and S. Park, "Deep learning-based body composition analysis for obesity-related health risk assessment," *IEEE Access*, vol. 8, pp. 128–140, 2020.
- [4] World Health Organization, "AI for Health Challenge 2022: Using artificial intelligence to improve global health outcomes," WHO Technical Report, Geneva, 2022.
- [5] T. N. Nguyen, H. M. Tran, and T. T. Pham, "Ứng dụng học sâu trong tính toán chỉ số BMI từ hình ảnh 2D," *Tạp chí Khoa học và Công nghệ Đại học Bách khoa Hà Nội*, tập 59, số 3, tr. 45–53, 2021.
- [6] P. T. Le and N. V. Hoang, "Kết hợp dữ liệu nhân trắc học và hình ảnh trong đánh giá nguy cơ thừa cân béo phì học máy," *Hội nghị Quốc gia về Công nghệ Thông tin và Truyền thông (REV-Conf)*, 2022.
- [7] Bộ Khoa học và Công nghệ Việt Nam, "Đề án AI cho sức khỏe cộng đồng," Báo cáo kỹ thuật, Hà Nội, 2023.
- [8] G. Jocher et al., "YOLOv8: Ultralytics real-time object detection model," 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics>
- [9] OpenAI, "Large Language Models for Health and Wellness Applications," Technical Overview, 2024. [Online]. Available: <https://openai.com/research>
- [10] MassNet: A Deep Learning Approach for Body Weight Extraction from a Single Pressure Image, *arXiv*, 2023.
- [11] US Patent US10679046B1: Machine Learning Systems for Estimating Body Shape from Images.
- [12] Extracting Multi-Dimensional Features for BMI Estimation Using a Multiplex Network, *MDPI*, 2024.
- [13] Role of ML-Based CT Body Composition in Risk Prediction, *PubMed Central*, 2023.
- [14] Leveraging Anthropometric Measurements to Improve Human Mesh Estimation, *arXiv*, 2024.
- [15] Pose-Normalized Image Generation for Person Re-identification, *ECCV*, 2018.
- [16] Hybrid ML Model for Body Fat Prediction (SVR-EANN), *MDPI*, 2021.
- [17] Enhancing Body Fat Prediction with WGAN-GP and XGBoost, *PubMed Central*, 2024.
- [18] Eliminate the Hardware: Mobile Food Recognition and Weight Estimation System, *NIH PMC*, 2022.
- [19] Saving Lives with AI Health Coaching, *OpenAI Research*, 2024.